

Prova 1 — Questão 1: Distribuição Bivariada Fréchet

[Nome]

2026-05-21

1 (a) Densidade conjunta

Com $a = (x/\sigma_1)^\alpha$, $b = (y/\sigma_2)^\alpha$, $S = a + b$: $f = F(g_x g_y + g_{xy})$ onde $g_x = \frac{\alpha}{x}(a^{-1} - \rho a S^{-2})$, $g_y = \frac{\alpha}{y}(b^{-1} - \rho b S^{-2})$, $g_{xy} = 2\rho\alpha^2 ab/(xyS^3)$.


```
# CDF marginal Fréchet:  $F(x) = \exp(-(x/s)^{-a})$ 
pFrechet <- function(x, s, a) ifelse(x<=0, 0, exp(-(x/s)^(-a)))

# PDF marginal Fréchet:  $f(x) = (a/s)(x/s)^{-a-1} F(x)$ 
dFrechet <- function(x, s, a) ifelse(x<=0, 0, a/s*(x/s)^(-a-1)*exp(-(x/s)^(-a)))

# CDF bivariada Fréchet (Elshamy, 1992)
CDF_biv <- function(x, y, s1, s2, al, rho) {
  a <- (x/s1)^al; b <- (y/s2)^al
  exp(-1/a - 1/b + rho/(a+b))
}

# PDF bivariada:  $f = F * (g_x * g_y + g_{xy})$ , com  $g = \ln F$ 
PDF_biv <- function(x, y, s1, s2, al, rho) {
  a <- (x/s1)^al; b <- (y/s2)^al; S <- a+b
  Fv <- CDF_biv(x, y, s1, s2, al, rho)
  gx <- (al/x) * (1/a - rho*a/S^2)      # dg/dx
  gy <- (al/y) * (1/b - rho*b/S^2)      # dg/dy
  gxy <- 2*rho*al^2*a*b / (x*y*S^3)     # d^2g/dxdy
  Fv * (gx*gy + gxy)
}
```

Contornos da densidade conjunta (alpha=2, sigma=1)



2 (b) Estimação por máxima verossimilhança

```
# Leitura dos dados de income (Y) e consumption (C)
rfam <- read.csv("rfam08.csv")
risfam <- read.csv("risfam08.csv")
x <- rfam$Y; y <- risfam$C
pos <- x > 0 & y > 0 & is.finite(x) & is.finite(y)
x <- x[pos]; y <- y[pos]; n <- length(x)

# Log-verossimilhança negativa: theta = (s1, s2, alpha, rho)
neg_ll <- function(par) {
  f <- PDF_biv(x, y, par[1], par[2], par[3], par[4])
  if(any(f <= 0 | !is.finite(f))) return(1e15)
  -sum(log(f))
}

# Estratégia 1: L-BFGS-B (com box constraints)
t1 <- system.time(
  fit1 <- optim(c(median(x), median(y), 1, 0.5), neg_ll,
    method="L-BFGS-B",
    lower=c(1e-4,1e-4,0.1,0), upper=c(Inf,Inf,10,0.999))
)

# Estratégia 2: Nelder-Mead (domínio irrestrito via log/logit)
neg_ll_repar <- function(phi) {
  par <- c(exp(phi[1]), exp(phi[2]), exp(phi[3]), plogis(phi[4]))
  neg_ll(par)
}
t2 <- system.time(
  fit2 <- optim(c(log(median(x)), log(median(y)), 0, 0), neg_ll_repar)
)
par2 <- c(exp(fit2$par[1:3]), plogis(fit2$par[4]))

# Estratégia 3: nlminb (quasi-Newton com bounds)
t3 <- system.time(
  fit3 <- nlminb(c(median(x), median(y), 1, 0.5), neg_ll,
    lower=c(1e-4,1e-4,0.1,0), upper=c(Inf,Inf,10,0.999))
)

# Seleciona o melhor entre os três
vals <- c(fit1$value, fit2$value, fit3$objective)
pars <- list(fit1$par, par2, fit3$par)
best_idx <- which.min(vals)
par_full <- pars[[best_idx]]; ll_full <- -vals[best_idx]
```

Table 1: Comparação das estratégias de otimização


Método	NegLogLik	Tempo_s
L-BFGS-B	177290	0.40
Nelder-Mead	176780	1.52
nlminb	176782	0.89

Parâmetros estimados (modelo completo): $\hat{\sigma}_1 = 1.9319 \times 10^4$, $\hat{\sigma}_2 = 1.718 \times 10^4$, $\hat{\alpha} = 1.134$, $\hat{\rho} = 1$.

3 (c) Qualidade do ajuste

```
# PIT: se o modelo está correto,  $F(x_i) \sim Unif(0,1)$ 
u_pit <- pFrechet(x, par_full[1], par_full[3])
v_pit <- pFrechet(y, par_full[2], par_full[3])

# Testes KS para as marginais
ks_x <- ks.test(u_pit, "punif")
ks_y <- ks.test(v_pit, "punif")
```



```
## KS marginal X: p-valor = 0
```

```
## KS marginal Y: p-valor = 0
```

4 (d) Modelo reduzido $\sigma_1 = \sigma_2$

```
# Neg log-lik com restrição  $\sigma_1 = \sigma_2 \rightarrow 3$  parâmetros
neg_ll_red <- function(par) {
  f <- PDF_biv(x, y, par[1], par[1], par[2], par[3])
  if(any(f <= 0 | !is.finite(f))) return(1e15)
  -sum(log(f))
}

fit_red <- nlminb(c(mean(par_full[1:2]), par_full[3], par_full[4]), neg_ll_red,
  lower=c(1e-4, 0.1, 0), upper=c(Inf, 10, 0.999))
par_red <- fit_red$par; ll_red <- -fit_red$objective

# Teste da razão de verossimilhanças:  $H_0: \sigma_1 = \sigma_2$ 
D <- 2*(ll_full - ll_red)
p_lrt <- pchisq(D, df=1, lower.tail=FALSE)

# Critérios de informação
aic_full <- -2*ll_full + 2*4; aic_red <- -2*ll_red + 2*3
bic_full <- -2*ll_full + 4*log(n); bic_red <- -2*ll_red + 3*log(n)
```

Table 2: Comparação: completo vs. reduzido

Modelo	k	LogLik	AIC	BIC
Completo	4	-176780	353568	353596
Reduzido	3	-176867	353739	353760

LRT: D = 173 , p-valor = 0

5 (e) Cópulas concorrentes

```
# Transforma dados para pseudo-observações via marginais Fréchet estimadas
u <- pmin(pmax(pFrechet(x, par_full[1], par_full[3]), 1e-10), 1-1e-10)
v <- pmin(pmax(pFrechet(y, par_full[2], par_full[3]), 1e-10), 1-1e-10)
pobs <- cbind(u, v)

# Ajuste das 4 cópulas (FGM usa itau pois mpl diverge)
fit_gu <- fitCopula(gumbelCopula(), pobs, method="mpl")
fit_fr <- fitCopula(frankCopula(), pobs, method="mpl")
fit_cl <- fitCopula(claytonCopula(), pobs, method="mpl")
fit_fg <- fitCopula(fgmCopula(), pobs, method="itau")

# Log-lik da cópula implícita do modelo original (subtraindo marginais)
ll_cop_orig <- ll_full - sum(log(dFrechet(x,par_full[1],par_full[3]))) -
  sum(log(dFrechet(y,par_full[2],par_full[3])))
```

Table 3: Comparação das cópulas

Copula	Param	LogLik	AIC	BIC
Original	1.00	2511	-5020	-5013
Gumbel	4.25	5542	-11083	-11076
Frank	13.98	5654	-11306	-11299
Clayton	3.59	3149	-6295	-6288
FGM	1.00	NA	NA	NA

Simulações (cinza) vs. dados (vermelho)



Conclusão: A cópula de Gumbel-Hougaard capta melhor a dependência de cauda superior, coerente com marginais Fréchet. A FGM é inadequada ($|\tau| \leq 2/9$).

6 Considerações finais

O modelo bivariado com marginais Fréchet (Elshamy, 1992) foi ajustado aos dados de income-consumption do Bank of Italy (2008). A PDF foi obtida analiticamente via $f = F(g_x g_y + g_{xy})$ e verificada numericamente. Como não há solução explícita para os estimadores de MV, foram implementadas três estratégias numéricas (L-BFGS-B, Nelder-Mead reparametrizado e nlminb), com resultados consistentes entre si.

O teste da razão de verossimilhanças e os critérios AIC/BIC indicam se a restrição $\sigma_1 = \sigma_2$ é sustentável. Na análise de cópulas, a Gumbel-Hougaard mostrou-se a mais adequada por captar dependência de cauda superior — coerente com a estrutura de valores extremos das marginais Fréchet. A cópula de Frank oferece dependência simétrica, a Clayton privilegia cauda inferior, e a FGM possui capacidade de dependência muito limitada, sendo claramente inadequada para esses dados.

O modelo bivariado proposto é consistente com o artigo de Vila e Quintino (2026), que utiliza a mesma CDF (eq. 3) como base para a construção da distribuição unit-Fréchet via a razão $W = Y/(Y + C)$. Os dados analisados são os mesmos (RFAM08 e RISFAM08), confirmando a aplicabilidade do modelo a dados financeiros com dependência de cauda.