

Prova 1 — Questão 1: Distribuição Bivariada Fréchet

[Nome]

2026-05-24

1 (a) Densidade conjunta

A CDF bivariada com marginais Fréchet (Elshamy, 1992; Vila & Quintino, 2025) é dada por

$$F(x, y) = \exp\left\{-\left(\frac{x}{\sigma_1}\right)^{-\alpha} - \left(\frac{y}{\sigma_2}\right)^{-\alpha} + \rho\left[\left(\frac{x}{\sigma_1}\right)^{\alpha} + \left(\frac{y}{\sigma_2}\right)^{\alpha}\right]^{-1}\right\}, \quad x, y > 0.$$

Note que as marginais são Fréchet: $F_X(x) = \lim_{y \rightarrow \infty} F(x, y) = e^{-(x/\sigma_1)^{-\alpha}}$. Quando $\rho = 0$, $F(x, y) = F_X(x)F_Y(y)$ (independência); $\rho \in [0, 1]$ controla a dependência.

A PDF é $f = \frac{\partial^2 F}{\partial x \partial y}$. Escrevendo $F = e^g$ com $g(x, y) = \ln F(x, y)$, a primeira derivada é $\frac{\partial F}{\partial x} = F g_x$. Derivando novamente em y :

$$f = \frac{\partial}{\partial y}(F g_x) = \frac{\partial F}{\partial y} g_x + F g_{xy} = F g_y g_x + F g_{xy} = F (g_x g_y + g_{xy}).$$

Definindo $a \equiv (x/\sigma_1)^\alpha$, $b \equiv (y/\sigma_2)^\alpha$, $S \equiv a + b$, temos $g = -a^{-1} - b^{-1} + \rho S^{-1}$. Como $\frac{\partial a}{\partial x} = \frac{\alpha a}{x}$ e b não depende de x :

$$g_x = \frac{\partial}{\partial x}(-a^{-1}) + \rho \frac{\partial}{\partial x}(S^{-1}) = \frac{\alpha}{x a} - \rho \frac{\alpha a}{x S^2}.$$

Analogamente para g_y . Para g_{xy} , derivamos g_x em y (só o termo com S^{-2} depende de y , via $\frac{\partial S}{\partial y} = \frac{\alpha b}{y}$):

$$g_x = \frac{\alpha}{x} \left(\frac{1}{a} - \frac{\rho a}{S^2} \right), \quad g_y = \frac{\alpha}{y} \left(\frac{1}{b} - \frac{\rho b}{S^2} \right), \quad g_{xy} = \frac{2\rho \alpha^2 ab}{xy S^3}.$$


```
# CDF marginal Fréchet: F(x) = exp(-(x/s)^(-a))
pFrechet <- function(x, s, a) ifelse(x <= 0, 0, exp(-(x/s)^(-a)))

# PDF marginal Fréchet: f(x) = (a/s)(x/s)^(-a-1) F(x)
dFrechet <- function(x, s, a) ifelse(x <= 0, 0, a/s*(x/s)^(-a-1)*exp(-(x/s)^(-a)))

# CDF bivariada Fréchet (Elshamy, 1992)
CDF_biv <- function(x, y, s1, s2, al, rho) {
  a <- (x/s1)^al; b <- (y/s2)^al
  exp(-1/a - 1/b + rho/(a + b))
}

# PDF bivariada: f = F * (g_x * g_y + g_xy), com g = ln F
PDF_biv <- function(x, y, s1, s2, al, rho) {
  a <- (x/s1)^al; b <- (y/s2)^al; S <- a + b
  Fv <- CDF_biv(x, y, s1, s2, al, rho)
  gx <- (al/x) * (1/a - rho*a/S^2)
  gy <- (al/y) * (1/b - rho*b/S^2)
  gxy <- 2*rho*al^2*a*b / (x*y*S^3)
  Fv * (gx*gy + gxy)
}
```

Contornos da densidade conjunta ($\alpha=2$, $\sigma=1$)



Os contornos ilustram o efeito do parâmetro ρ : para $\rho = 0$ a densidade é simétrica e os contornos são aproximadamente elípticos (independência), enquanto para $\rho = 0.9$ os contornos se concentram ao longo da diagonal, indicando forte associação positiva entre X e Y .

2 (b) Estimação por máxima verossimilhança

```
# Leitura dos dados com readr e limpeza com dplyr
df_raw <- inner_join(
  read_csv("rfam08.csv", show_col_types = FALSE) %>% select(nquest, income = Y),
  read_csv("risfam08.csv", show_col_types = FALSE) %>% select(nquest, consumption = C),
  by = "nquest"
) %>%
  mutate(income = as.numeric(income),
         consumption = as.numeric(consumption)) %>%
  filter(income > 0, consumption > 0,
         is.finite(income), is.finite(consumption))

# Vetores para a otimização
x <- df_raw$income
y <- df_raw$consumption
n <- nrow(df_raw)

# Log-verossimilhança negativa: theta = (s1, s2, alpha, rho)
neg_ll <- function(par) {
  f <- PDF_biv(x, y, par[1], par[2], par[3], par[4])
  if (any(f <= 0 | !is.finite(f))) return(1e15)
  -sum(log(f))
}

# Estratégia 1: L-BFGS-B
t1 <- system.time(
  fit1 <- optim(c(median(x), median(y), 1, 0.5), neg_ll,
               method = "L-BFGS-B",
               lower = c(1e-4, 1e-4, 0.1, 0),
               upper = c(Inf, Inf, 10, 0.999))
)
```

```

)

# Estratégia 2: Nelder-Mead
neg_ll_repar <- function(phi) {
  par <- c(exp(phi[1]), exp(phi[2]), exp(phi[3]), plogis(phi[4]))
  neg_ll(par)
}
t2 <- system.time(
  fit2 <- optim(c(log(median(x)), log(median(y)), 0, 0), neg_ll_repar)
)
par2 <- c(exp(fit2$par[1:3]), plogis(fit2$par[4]))

# Estratégia 3: nlminb
t3 <- system.time(
  fit3 <- nlminb(c(median(x), median(y), 1, 0.5), neg_ll,
    lower = c(1e-4, 1e-4, 0.1, 0),
    upper = c(Inf, Inf, 10, 0.999))
)

# Seleciona o melhor entre os três
resultados <- tibble(
  metodo = c("L-BFGS-B", "Nelder-Mead", "nlminb"),
  neg_ll = c(fit1$value, fit2$value, fit3$objective),
  tempo_s = c(t1[3], t2[3], t3[3]),
  par_list = list(fit1$par, par2, fit3$par)
) %>%
  mutate(melhor = neg_ll == min(neg_ll))

best_idx <- which.min(resultados$neg_ll)
par_full <- resultados$par_list[[best_idx]]
ll_full <- -resultados$neg_ll[best_idx]

```

Table 1: Comparação das estratégias de otimização

Método	NegLogLik	Tempo_s
L-BFGS-B	177290	0.39
Nelder-Mead	176780	1.47
nlminb	176782	0.91

Parâmetros estimados (modelo completo): $\hat{\sigma}_1 = 1.9319 \times 10^4$, $\hat{\sigma}_2 = 1.718 \times 10^4$, $\hat{\alpha} = 1.134$, $\hat{\rho} = 1$.

As três estratégias convergem para valores similares de log-verossimilhança, o que indica robustez da estimação. A melhor estratégia foi **Nelder-Mead**. O valor estimado $\hat{\rho} = 1.000$ indica dependência positiva entre renda e consumo. Como não há forma fechada para os EMV (a log-verossimilhança envolve somas e produtos não-separáveis dos parâmetros), a otimização numérica é indispensável.

3 (c) Qualidade do ajuste

```

# PIT: se o modelo está correto,  $F(x_i) \sim Unif(0,1)$ 
df_pit <- df_raw %>%
  mutate(u_pit = pFrechet(income, par_full[1], par_full[3]),
    v_pit = pFrechet(consumption, par_full[2], par_full[3]))

```

```
# Testes KS para as marginais
ks_x <- ks.test(df_pit$u_pit, "punif")
ks_y <- ks.test(df_pit$v_pit, "punif")
```




Table 2: Teste KS para as marginais Fréchet

Marginal	p-valor KS
Income (X)	0
Consumption (Y)	0

O teste KS rejeita H_0 para a marginal de Income ($p = 0.0000$) e rejeita H_0 para Consumption ($p = 0.0000$) ao nível de 5%. Note que, com $n = 7957$ observações, o teste KS tem alto poder e tende a rejeitar mesmo para desvios pequenos do modelo teórico. Os Q-Q-plots fornecem uma avaliação visual complementar: desvios nas caudas indicam que o modelo pode não captar perfeitamente os valores extremos.

4 (d) Modelo reduzido $\sigma_1 = \sigma_2$

```
# Neg log-lik com restrição sigma1 = sigma2 -> 3 parâmetros
neg_ll_red <- function(par) {
  f <- PDF_biv(x, y, par[1], par[1], par[2], par[3])
  if (any(f <= 0 | !is.finite(f))) return(1e15)
  -sum(log(f))
}
fit_red <- nlminb(c(mean(par_full[1:2]), par_full[3], par_full[4]), neg_ll_red,
  lower = c(1e-4, 0.1, 0), upper = c(Inf, 10, 0.999))
par_red <- fit_red$par
ll_red <- -fit_red$objective

# Teste da razão de verossimilhanças: H0: sigma1 = sigma2
D <- 2 * (ll_full - ll_red)
p_lrt <- pchisq(D, df = 1, lower.tail = FALSE)
```

```
# Critérios de informação
tab_modelos <- tibble(
  Modelo = c("Completo (4 par)", "Reduzido (3 par)"),
  k       = c(4, 3),
  LogLik  = c(ll_full, ll_red)
) %>%
  mutate(AIC = -2*LogLik + 2*k,
         BIC = -2*LogLik + k*log(n))
```

Table 3: Comparação: completo vs. reduzido

Modelo	k	LogLik	AIC	BIC
Completo (4 par)	4	-176780	353568	353596
Reduzido (3 par)	3	-176867	353739	353760

```
## LRT: D = 173 , p-valor = 0
```

O teste da razão de verossimilhanças rejeita $H_0 : \sigma_1 = \sigma_2$ ($D = 172.999$, $p = 0.0000$), indicando que o modelo completo com 4 parâmetros é estatisticamente superior ao reduzido. O critério AIC favorece o modelo **Completo (4 par)** e o BIC favorece o modelo **Completo (4 par)**. Como o BIC penaliza mais fortemente a complexidade para amostras grandes ($n = 7957$), sua indicação tende a ser mais conservadora.

5 (e) Cópias concorrentes

```
# Transforma dados para pseudo-observações via marginais Fréchet estimadas
df_pseudo <- df_raw %>%
  mutate(u = pFrechet(income, par_full[1], par_full[3]),
         v = pFrechet(consumption, par_full[2], par_full[3]),
         u = pmin(pmax(u, 1e-10), 1 - 1e-10),
         v = pmin(pmax(v, 1e-10), 1 - 1e-10))

pobs <- df_pseudo %>% select(u, v) %>% as.matrix()

# Ajuste das 4 cópias (FGM usa itau pois mpl diverge)
fit_gu <- fitCopula(gumbelCopula(), pobs, method = "mpl")
fit_fr <- fitCopula(frankCopula(), pobs, method = "mpl")
fit_cl <- fitCopula(claytonCopula(), pobs, method = "mpl")
fit_fg <- fitCopula(fgmCopula(), pobs, method = "itau")

# Log-lik da cópia implícita do modelo original (subtraindo marginais)
ll_cop_orig <- ll_full -
  sum(log(dFrechet(x, par_full[1], par_full[3]))) -
  sum(log(dFrechet(y, par_full[2], par_full[3])))

# Tabela comparativa com dplyr
tab_copulas <- tibble(
  Copula = c("Original (Fréchet biv.)", "Gumbel-Hougaard",
            "Frank", "Clayton", "FGM"),
  Param = c(par_full[4], coef(fit_gu), coef(fit_fr),
            coef(fit_cl), coef(fit_fg)),
  LogLik = c(ll_cop_orig, as.numeric(logLik(fit_gu)),
            as.numeric(logLik(fit_fr)), as.numeric(logLik(fit_cl)),
```


```

as.numeric(logLik(fit_fg)))
) %>%
mutate(AIC = -2*LogLik + 2,
       BIC = -2*LogLik + log(n))

```

Table 4: Comparação das cópulas

Copula	Param	LogLik	AIC	BIC
Original (Fréchet biv.)	1.00	2511	-5020	-5013
Gumbel-Hougaard	4.25	5542	-11083	-11076
Frank	13.98	5654	-11306	-11299
Clayton	3.59	3149	-6295	-6288
FGM	1.00	NA	NA	NA



Conclusão: A cópula de Gumbel-Hougaard capta melhor a dependência de cauda superior, coerente com marginais Fréchet. A FGM é inadequada ($|\tau| \leq 2/9$).